

Национальный исследовательский Томский государственный университет
НОЦ «Высшая ИТ школа»

Лабораторная работа по курсу
МКН ч.3
«Статистика»

Преподаватель Ким К.С.

Томск 2025

Введение

В данном модуле вам предстоит познакомиться с пакетом R или пакетом R-studio (второе предпочтительнее из-за более удобного интерфейса) и сделать 2 лабораторные работы, которые будут описаны ниже. Синтаксис у пакетов одинаковый, поэтому бояться не нужно.

Ваша задача:

1) Установить пакет (пакеты). Переходите по ссылке, которые указаны в гугл классе. Также там прикреплена методичка с описанием синтаксиса.

2) Разобраться с синтаксисом пакета

3) Выполнить лабораторную работу 1 и 2. За лабораторную 1 (Лаба 1) вы можете получить максимум 10 баллов, за лабораторную 2 (Лаба 2) максимум 20 баллов. **Важно! Без лабораторной 1 лабораторная 2 не принимается.**

4) Лабораторные выполняются с определённым датасетом. Скачиваем нужный вам архив с гугл класса. Посмотреть какой архив нужно скачать можно в таблице с оценками.

5) После скачивания своего датасета его необходимо проредить, для этого в пакете берем только 200 случайных значений (строк), потому что при больших данных довольно маленький простор для гипотез. Этот урезанный датасет вы используете в обеих лабораторных.

6) **Использовать встроенные функции в пакетах можно только для проверки своих вычислений. Все расчеты производим напрямую без встроенных!**

Лаба 1 «Визуализация данных»

ЗАДАНИЕ

1) В выданном датасете выявите признак, зависящий от других, пусть он называется целевым (X), далее ваша задача — выявить, какие признаки (Y_i) влияют на целевой признак. Избегайте включения в модель признаков, находящихся в тривиальной зависимости (например, зависимость между метрами и километрами считалась бы тривиальной)

2) Используя R / R-studio, визуализируйте распределение X и Y_i в датасете с помощью гистограмм и полигонов частот. Уберите выбросы при необходимости.

3) Рассчитайте основные статистические характеристики (среднее, медиана, мода, дисперсия, СКО) для X и Y .

Лаба 2 «Интервальное оценивание и проверка гипотез»

ЗАДАНИЕ

Обычно в частотной статистике до сбора данных формулируется нулевая гипотеза об отсутствии каких-то статистически значимых отклонений.

Сформулируйте гипотезу о том, какое среднее значение у X (например что-то предсказуемое). На основе имеющихся данных проверьте эту гипотезу:

1. Используйте уровень значимости α , по которому будет сделан вывод о том верна ли гипотеза, равный 0.05. (Проверьте что будет если использовать другие.)

2. Найдите границы доверительного интервала для среднего значения при выбранном уровне значимости

3. Сделайте выводы об истинности гипотезы

4. Другой способ проверки гипотез заключается в нахождении P -value — вероятности:

- получить в результате эксперимента значения статистики при корректности нулевой гипотезы.

- Найдите значение P -value и сделайте вывод об истинности гипотезы. (спойлер, вывод должен совпасть с проверкой через доверительные интервалы)

5. Проведите нормализацию признаков

6. Реализуйте с нуля модель линейной регрессии с использованием градиентного спуска:

- самостоятельно выберите функцию потерь;
- добавьте колонку-смещение (intercept);
- реализуйте остановку по достижению малого изменения функции потерь (epsilon);

- визуализируйте изменение значения функции потерь по итерациям.

7. Постройте функцию предсказания по новой выборке на основе обученной модели.

8. Посчитайте метрики качества на тестовой выборке:

- MSE
- RMSE
- R^2

9. Сравните результаты с моделью, построенной с помощью встроенной функции `lm()`